

Tony LI

Kinen NARDIN



Université
Paris Cité

TAIPEI



Projet : Real Estate

Table des Matières :

<u>I / Analyse des données et des variables</u>	3
1) <i>Analyse descriptive du jeu de données</i>	3
2) <i>Analyse des variables du jeu de données</i>	4
<u>II/ Analyse Bivariée du jeu de donnée</u>	7
1) <i>Analyse bivariée en fonction du PRIX DE LA MAISON</i>	7
2) <i>Analyse bivariée en fonction du NOMBRE DE MAGASIN</i>	9
<u>III/ Modèle de régression simple</u>	10
<u>IV/ Modèle de régression multiple</u>	14
<u>V/ Analyse en composante principale et Classification ascendante hiérarchique</u>	16
<u>Conclusion</u>	

I/Analyse des données et des variables

1) Analyse descriptive du jeu de données :

Nous disposons d'un jeu de données comprenant 7 variables et 414 observations, fournissant une base riche et diversifiée pour l'analyse et la modélisation statistique.

Dans cette partie nous allons vous les présenter :

DateAchat (x1) : La variable quantitative "date d'achat" fait référence à la date à laquelle un achat a été effectué. Cette variable est représentée sous forme de données temporelles, telles que des jours, des mois et des années.

AgeMaison (x2) : La variable quantitative "âge de la maison" fait référence à la durée depuis la construction de la maison en années. Elle représente donc la mesure du temps écoulé depuis la date de construction jusqu'à la date actuelle

Distance MRT (x3) : La variable quantitative "distanceMRT" représente la distance, en mètres entre le lieu de résidence et le transport en commun le plus proche, souvent le métro (MRT pour Mass Rapid Transit).

NbreMagasin (x4) : La variable qualitative "nbre magasin" représente le nombre de magasins situés dans les environs d'un emplacement donné. Cette variable catégorique peut être utilisée pour caractériser le niveau d'accessibilité commerciale d'une zone spécifique.

Latitude et Longitude (x5 et x6) : Les variables quantitatives "latitude" et "longitude" représentent respectivement la position géographique en termes de latitude et de longitude d'un lieu spécifique sur la surface de la Terre.


PrixMaison (y) : La variable quantitative "prixMaison" représente le prix d'une maison ou d'un bien immobilier. Cette variable numérique mesure la valeur monétaire associée à une propriété et est exprimée en TWD (Nouveau dollar Taïwanais). En analysant cette variable, on peut étudier les tendances du marché immobilier, évaluer la valeur d'une propriété et prendre des décisions en matière d'investissement immobilier.

Nous allons maintenant expliciter les différentes variables sur la durée août 2012 à juillet 2013.

2) Analyse des variables du jeu de données

DateAchat :

La procédure UNIVARIATE Variable : dateAchat (X1 transaction date)			
Moments			
N	414	Somme des poids	414
Moyenne	2013.14895	Somme des observations	833443.667
Ecart-type	0.28199533	Variance	0.07952136
Skewness	-0.1508343	Kurtosis	-1.2319464
Somme des carrés non corrigée	1677846278	Somme des carrés corrigée	32.8423236
Coeff Variation	0.01400767	Std Error Mean	0.01385931




Nous pouvons remarquer un pic d'achat de maison en mai 2013 ainsi que des pics moins importants mais plus conséquent que la moyenne en novembre 2012, janvier et juin 2013

AgeMaison :

La procédure UNIVARIATE
Variable : ageMaison (X2 house age)

Moments			
N	414	Somme des poids	414
Moyenne	17.7125604	Somme des observations	7333
Ecart-type	11.3924845	Variance	129.788704
Skewness	0.38292623	Kurtosis	-0.8771201
Somme des carrés non corrigée	183488.94	Somme des carrés corrigée	53602.7347
Coeff Variation	64.3186772	Std Error Mean	0.55991007



La base de données des âges des maison est dispatchée entre 0 et 43 ans.


Nous observons 3 pics :

- entre 0 et 6 ans
- entre 12 et 18 ans (le plus élevé)
- entre 30 et 36 ans

DistanceMRT :

La procédure UNIVARIATE
Variable : distanceMRT (X3 distance to the nearest MRT station)

Moments			
N	414	Somme des poids	414
Moyenne	1083.88569	Somme des observations	448728.675
Ecart-type	1262.1096	Variance	1592920.63
Skewness	1.88875658	Kurtosis	3.20786837
Somme des carrés non corrigée	1144246810	Somme des carrés corrigée	657876221
Coeff Variation	116.443054	Std Error Mean	62.0293025




Nous pouvons voir que la grande majorité des maisons sont au plus à 1 km de distance du MRT le plus proche

NbreMagasin :

La procédure FREQ

nombre_magasins_qualitative	Fréquence	Pourcentage	Fréquence cumulée	Pourcentage cumulé
0 à 3	183	44.20	183	44.20
4 à 6	135	32.61	318	76.81
6 à 1	96	23.19	414	100.00




On remarque que 4 Taipéiens/Taipéiennes sur 10 ont accès à au plus 3 commodités. Ce qui représente environ 1,2 millions d'habitants.

Latitude et Longitude :


La procédure UNIVARIATE
Variable : latitude (X5 latitude)

Moments			
N	414	Somme des poids	414
Moyenne	24.9690301	Somme des observations	10337.1784
Ecart-type	0.0124102	Variance	0.00015401
Skewness	-0.4385984	Kurtosis	0.26906978
Somme des carrés non corrigée	258109.383	Somme des carrés corrigée	0.06360736
Coeff Variation	0.04970236	Std Error Mean	0.00060993




La procédure UNIVARIATE
Variable : longitude (X6 longitude)

Moments			
N	414	Somme des poids	414
Moyenne	121.533361	Somme des observations	50314.8115
Ecart-type	0.01534718	Variance	0.00023554
Skewness	-1.2195915	Kurtosis	1.20179246
Somme des carrés non corrigée	6114928.25	Somme des carrés corrigée	0.09727638
Coeff Variation	0.01262796	Std Error Mean	0.00075427



PrixMaison :

La procédure UNIVARIATE Variable : prixMaison (Y house price of unit area)			
Moments			
N	414	Somme des poids	414
Moyenne	37.9801932	Somme des observations	15723.8
Ecart-type	13.6064877	Variance	185.136507
Skewness	0.59985258	Kurtosis	2.17909705
Somme des carrés non corrigée	673654.34	Somme des carrés corrigée	76461.3776
Coeff Variation	35.8252198	Std Error Mean	0.66872239




Nous observons ce qui suit sur la distribution des prix des maisons par unité de surface :


- Les prix des maisons par unité de surface varient considérablement, de 76 000 dollars taïwanais par mètre carré à plus d'un million de dollars taïwanais.
- Plus de la moitié des prix des maisons par unité de surface se situent entre 250 000 et 500 000 dollars taïwanais.
- Il y a 8 maisons pour lesquelles le prix par unité de surface est supérieur à 760 000 dollars taïwanais, dont une atteignant 1 175 000 dollars taïwanais (valeur extrême).

II/ Analyse bivariable du jeu de données


1) Analyse bivariable en fonction de prixMaison




Le premier graphique révèle une tendance à la hausse du prix des maisons, dépassant les 60 €/m² après le début de 2013. Avant le début de l'année 2013, le prix des maisons était généralement inférieur à 60 €/m², avec seulement un point aberrant en août 2012.




Le graphique présente la relation entre le prix des maisons et l'âge des maisons. Les maisons vont de récemment construites (0 ans) à un âge allant jusqu'à près de 43 ans. Cependant, le prix des maisons sur la période de 12 mois ne montre pas de tendance évidente. Cela pourrait suggérer que l'âge de la maison n'est pas aussi pertinent pour le prix des maisons, mais cela sera vérifié en ajustant les modèles de régression dans les sections suivantes.




Le graphique met en évidence une tendance claire à la baisse entre le prix des maisons et la distance de la maison à la station de MRT la plus proche (station de métro publique). Les maisons avec le prix de vente le plus élevé sont situées à moins de 1000 mètres d'une station de MRT, puis à moins de 2000 mètres d'une station de MRT. Cela pourrait donc impliquer que la variable distance à la station de MRT est un prédicteur important du prix des maisons.



Le graphique met en évidence la relation entre le prix des maisons et le nombre de magasins de proximité. On observe une tendance à la hausse entre ces deux variables, bien que légèrement prononcée. Seulement lorsque le nombre de magasins de proximité est inférieur à 3, les prix des maisons passent en dessous de 20 €/m². Lorsqu'il y a plus de 6 magasins de proximité aux alentours, la plupart des prix des maisons dépassent 40 €/m². En présence de 10 magasins de proximité, la majorité des prix des maisons se situe autour de 50 €/m². Cela suggère à nouveau que la variable nombre de magasins de proximité pourrait également être un prédicteur important du prix des maisons.





Le graphique met en évidence la relation entre le prix des maisons et leur emplacement en termes de coordonnées de latitude et de longitude. Il est clairement observé que les prix des maisons présentent une distribution circulaire. Les maisons situées dans des zones denses ou dans un cercle intérieur affichent des prix plus élevés (points rouges / jaunes / verts), tandis que les maisons avec des prix plus bas sont localisées loin des zones denses, dans la périphérie où se trouvent seulement quelques habitations (points bleus). Ainsi, l'emplacement peut jouer un rôle important en tant que prédicteur du prix des maisons. En effet, on remarque que la zone la plus peuplée est le centre est (en accord avec l'analyse univariée des variables latitude et longitude ci-dessus.)



On obtient ce graphique avec le package MGCV de R. On remarque une corrélation entre les remarques qu'on a pu faire sur le graphique au-dessus. En effet on voit que la zone centre est admet des valeurs positives pour les courbes. Cela indique une forte corrélation entre les variables latitude/longitude et prixMaison.

2) Analyse bivariée en fonction du nombre de magasin





Nous pouvons observer plusieurs choses au travers de ces graphiques :

Concernant la variable `ageMaison`, on remarque qu'il n'existe aucune corrélation avec le nombre de magasins. En effet la disposition du nombre de commodité est régulière peu importe la date d'achat de la maison. Concernant la variable `distance MRT`, on remarque que la majorité des magasins se situent à proximité des stations MRT. Cela pourrait signifier qu'elle est un indicateur important.

Concernant les variables longitude et latitude, les graphes appuient notre hypothèse selon laquelle la zone la plus habitée est le centre-est. Ainsi elle est un indicateur du nombre de magasins.

III/ Modèle de régression linéaire

Dans cette partie, nous allons construire des modèles de régressions linéaire. Ces modèles nous permettent d'établir une relation entre une variable explicative et une variable explicative.

Ici la variable que l'on cherche à expliquer est `prixMaison`.

La procédure REG

Modèle : MODEL1

Variable dépendante : prixMaison Y house price of unit area

Nb d'observations lues	414
Nb d'obs. utilisées	414

Analyse de variance

Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	585.79912	585.79912	3.18	0.0752
Erreur	412	75876	184.16403		
Total sommes corrigées	413	76461			

Root MSE	13.57070	R carré	0.0077
Moyenne dépendante	37.98019	R car. ajust.	0.0053
Coeff Var	35.73100		

Paramètres estimés

Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	-8464.25882	4767.17788	-1.78	0.0765
dateAchat	X1 transaction date	1	4.22335	2.36802	1.78	0.0752

On voit que :

- La valeur F associée est de 3.18 avec une valeur p de 0.0752. Cela indique que le modèle dans son ensemble peut ne pas être statistiquement significatif au niveau de signification de 0.05.
- Le coefficient de détermination (R^2) est de 0.0077, ce qui signifie que le modèle explique seulement 0.77% de la variance du prix des maisons.
- Le coefficient de détermination ajusté (R^2 ajusté) est de 0.0053.
- Paramètres estimés :
 - Pour la variable "dateAchat" (X1 transaction date), la valeur estimée du coefficient est 4.22335 avec une erreur type de 2.36802. Le test t associé a une valeur de 1.78 avec une valeur p de 0.0752, ce qui suggère que la relation entre la date d'achat et le prix des maisons n'est pas significativement différente de zéro au niveau de signification de 0.05.

La procédure REG

Modèle : MODEL1

Variable dépendante : prixMaison Y house price of unit area

Nb d'observations lues	414
Nb d'obs. utilisées	414

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	3390.18134	3390.18134	19.11	<.0001
Erreur	412	73071	177.35727		
Total sommes corrigées	413	76461			

Root MSE	13.31756	R carré	0.0443
Moyenne dépendante	37.98019	R car. ajust.	0.0420
Coeff Var	35.06447		

Paramètres estimés						
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	42.43470	1.21098	35.04	<.0001
ageMaison	X2 house age	1	-0.25149	0.05752	-4.37	<.0001

On voit que :

- La valeur F associée est de 19.11 avec une très faible valeur p (<.0001), indiquant que le modèle dans son ensemble est statistiquement significatif.
- Le coefficient de détermination (R^2), qui mesure la proportion de la variance de la variable dépendante expliquée par le modèle. Dans cet exemple, il est de 0.0443, ce qui signifie que le modèle explique environ 4.43% de la variance de la variable dépendante.
- R ajusté : Le coefficient de détermination ajusté (R^2 ajusté) est de 0.0420.
 - le coefficient de la variable indépendante "âge de la maison" (X2 house age). Dans cet exemple, la valeur estimée du coefficient est de -0.25149, ce qui signifie qu'une augmentation d'une unité dans l'âge de la maison est associée à une diminution de 0.25149 unités dans la variable dépendante (prix maison), toutes choses étant égales par ailleurs. Le test t associé a une valeur de -4.37 avec une très faible valeur p (<.0001), indiquant que le coefficient est statistiquement significatif.

La procédure GLM					
Informations sur les niveaux de classe					
Classe	Niveaux	Valeurs			
nombre_magasins_qualitative	3	0 à 3 4 à 6 6 à 1			
Nombre d'observations lues		414			
Nombre d'observations utilisées		414			

La procédure GLM					
Variable dépendante : prixMaison Y house price of unit area					
Source	DDL	Somme des carrés	Carré moyen	Valeur F	Pr > F
Modèle	2	25572.09077	12786.04539	103.26	<.0001
Erreur	411	50889.28681	123.81822		
Total sommes corrigées	413	76461.37758			

R-carré	Coef de var	Racine MSE	prixMaison Moyenne
0.334445	29.29781	11.12736	37.98019

Source	DDL	Type I SS	Carré moyen	Valeur F	Pr > F
nombre_magasins_qual	2	25572.09077	12786.04539	103.26	<.0001

Source	DDL	Type III SS	Carré moyen	Valeur F	Pr > F
nombre_magasins_qual	2	25572.09077	12786.04539	103.26	<.0001

Ces résultats montrent une analyse de régression linéaire entre la variable dépendante "prixMaison" (prix unitaire des maisons) et la variable qualitative "nombre_magasins_qualitative" (nombre de magasins regroupé en trois niveaux : 0 à 3, 4 à 6, et 6 et plus).

On voit que :

Le modèle dans son ensemble est statistiquement significatif, avec une valeur p très faible (<.0001). Cela signifie que la variable "nombre_magasins_qualitative" contribue de manière significative à expliquer la variation du prix des maisons.

Le coefficient de détermination (R^2) est de 0.334445, ce qui signifie que le modèle explique environ 33.44% de la variance dans le prix des maisons. Cela indique une correspondance modérée entre la variable indépendante et la variable dépendante.

La valeur F associée à la variable "nombre_magasins_qualitative" est de 103.26 avec une valeur p très faible (<.0001). Cela indique que le nombre de magasins a un effet significatif sur le prix des maisons.

La procédure REG					
Modèle : MODEL1					
Variable dépendante : prixMaison Y house price of unit area					
Nb d'observations lues		414			
Nb d'obs. utilisées		414			

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	34895	34895	342.24	<.0001
Erreur	412	41787	101.37549		
Total sommes corrigées	413	76461			

Root MSE	10.08854	R carré	0.4538
Moyenne dépendante	37.98019	R car. ajust.	0.4524
Coef Var	26.50997		

Paramètres estimés						
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	45.85143	0.68261	70.26	<.0001
distanceMRT	X3 distance to the nearest MRT station	1	-0.00726	0.00039255	-18.50	<.0001

On voit que :

La valeur F associée est de 342.24 avec une très faible valeur p (<.0001), indiquant que le modèle dans son ensemble est statistiquement significatif.

- Le coefficient de détermination (R^2), qui mesure la proportion de la variance de la variable dépendante expliquée par le modèle. Dans cet exemple, il est de 0.4538, ce qui signifie que le modèle explique environ 45.38% de la variance de la variable dépendante.

- R ajusté : Le coefficient de détermination ajusté (R^2 ajusté) est de 0.4524

Le coefficient de la variable indépendante "distanceMRT ". La valeur estimée du coefficient est de -0.00726, ce qui signifie qu'une augmentation de l'unité de la distance de la maison à la station MRT la plus proche est associée à une diminution de 0.00726 unités dans la variable dépendante (prix maison), toutes choses étant égales par ailleurs. Le test t associé a une valeur de -18.50 avec une très faible valeur p (<.0001), indiquant que le coefficient est statistiquement significatif.

La procédure REG

Modèle : MODEL1

Variable dépendante : prixMaison Y house price of unit area

Nb d'observations lues	414
Nb d'obs. utilisées	414

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	22820	22820	175.27	<.0001
Erreur	412	53641	130.19759		
Total sommes corrigées	413	76461			

Root MSE	11.41042	R carré	0.2985
Moyenne dépendante	37.98019	R car. ajust.	0.2987
Coeff Var	30.04307		

Paramètres estimés						
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	-14918	1129.66457	-13.21	<.0001
latitude	X5 latitude	1	598.96833	45.24262	13.24	<.0001

On voit que :

Le modèle dans son ensemble est statistiquement significatif, avec une valeur p très faible (<.0001). Cela indique que la latitude a un effet significatif sur le prix des maisons.

Le coefficient de détermination (R^2) est de 0.2985, ce qui signifie que le modèle explique environ 29.85% de la variance dans le prix des maisons. Cela indique une correspondance modérée entre la latitude et le prix des maisons.

La valeur F associée à la latitude est de 175.27 avec une valeur p très faible (<.0001). Cela indique que la latitude a un effet significatif sur le prix des maisons.

Le coefficient de la variable indépendante "latitude" est de 598.96833, avec une erreur standard de 45.24262. Le test t associé a une valeur de 13.24 avec une très faible valeur p (<.0001), indiquant que le coefficient est statistiquement significatif.

La procédure REG

Modèle : MODEL1

Variable dépendante : prixMaison Y house price of unit area

Nb d'observations lues	414
Nb d'obs. utilisées	414

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	1	20937	20937	155.36	<.0001
Erreur	412	56524	134.76711		
Total sommes corrigées	413	76461			

Root MSE	11.60892	R carré	0.2738
Moyenne dépendante	37.98019	R car. ajust.	0.2721
Coeff Var	30.56573		

Paramètres estimés						
Variable	Libellé	DDL	Valeur estimée des paramètres	Erreur type	Valeur du test t	Pr > t
Intercept	Intercept	1	-58346	4523.59592	-12.46	<.0001
longitude	X6 longitude	1	463.93481	37.22102	12.46	<.0001

On voit que :

Le modèle dans son ensemble est statistiquement significatif, avec une valeur p très faible (<.0001). Cela indique que la longitude a un effet significatif sur le prix des maisons.

Le coefficient de détermination (R^2) est de 0.2738, ce qui signifie que le modèle explique environ 27.38% de la variance dans le prix des maisons. Cela indique une correspondance modérée entre la longitude et le prix des maisons.

La valeur F associée à la longitude est de 155.36 avec une valeur p très faible (<.0001). Cela indique que la longitude a un effet significatif sur le prix des maisons.

Le coefficient de la variable indépendante "longitude" est de 463.93481, avec une erreur standard de 37.22102. Le test t associé a une valeur de 12.46 avec une très faible valeur p (<.0001), indiquant que le coefficient est statistiquement significatif.

Ainsi nous avons :

1. Pour la **date d'achat** : Le modèle de régression linéaire dans son ensemble n'est pas significatif pour prédire le prix des maisons en fonction de la date d'achat. Ainsi, la date d'achat n'a pas d'influence significative sur le prix des maisons dans cet ensemble de données.
2. Pour l'**âge de la maison** : Les résultats suggèrent une relation significative entre l'âge de la maison et le prix de la maison. Cependant, pour une compréhension complète des déterminants du prix des maisons, d'autres variables et facteurs doivent être examinés.
3. Pour la **distance à la station MRT** : Les résultats montrent une relation significative entre la distance de la maison à la station MRT la plus proche et le prix de la maison. De plus, l'écart-type de 0.65261 dans l'intercept indique que les valeurs observées sont proches de la moyenne.
4. Pour le **nombre de magasins** : Les résultats suggèrent que le nombre de magasins a un effet significatif sur le prix des maisons. La variation dans le prix des maisons peut être en partie expliquée par cette variable qualitative regroupée en trois niveaux comme nous l'avons fait.
5. Pour la **latitude et longitude** : Les résultats indiquent une relation significative entre la latitude et le prix des maisons. Une augmentation de la latitude est associée à une augmentation du prix des maisons, toutes choses étant égales par ailleurs. En conclusion, ces résultats indiquent qu'il existe une relation significative entre la longitude et le prix des maisons. Une augmentation de la longitude est associée à une augmentation du prix des maisons, toutes choses étant égales par ailleurs.

IV/ Modèle de régressions multiples

Pour explorer et évaluer les relations entre les variables explicatives et la variable cible dans notre ensemble de données, nous allons construire trois modèles de régression en utilisant des approches différentes : backward, forward et stepwise. Ces méthodes nous permettront d'identifier les variables les plus significatives pour prédire notre variable cible, en tenant compte de différentes stratégies de sélection de variable.

Méthode 1 : BACKWARD

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	4	43670	10917	136.17	<.0001
Erreur	409	32792	80.17505		
Total sommes corrigées	413	76461			

Variable	Valeur estimée des paramètres	Erreur type	SC Type II	Valeur F	Pr > F
Intercept	-5916.00644	1112.73216	2266.28861	28.27	<.0001
ageMaison	-0.26872	0.03893	3820.16710	47.65	<.0001
distanceMRT	-0.00418	0.00049276	5755.77215	71.79	<.0001
nbreMagasin	1.16478	0.18967	3023.62372	37.71	<.0001
latitude	238.63573	44.56086	2299.33880	28.68	<.0001

Modèle 1 :

Nous avons d'abord utilisé une élimination manuelle vers l'arrière pour sélectionner le meilleur modèle. En partant du modèle complet, la variable la moins significative (avec la plus grande valeur $Pr > F$) est x6 (longitude), donc elle est d'abord supprimée. Ensuite, la variable suivante la moins significative dans le modèle est x1 (dateAchat), puis après avoir supprimé x1, tous les coefficients de variable dans le modèle sont significatifs, donc nous arrêtons et obtenons le modèle1 :
 $y \sim x_2 + x_3 + x_4 + x_5$

Méthode 2 : FORWARD et STEPWISE

Variable	Valeur estimée des paramètres	Erreur type	SC Type II	Valeur F	Pr > F
Intercept	-15965	3233.11131	1908.59431	24.38	<.0001
dateAchat	5.13755	1.55445	855.04344	10.92	0.0010
ageMaison	-0.26938	0.03847	3838.88990	49.04	<.0001
distanceMRT	-0.00435	0.00048986	6181.89987	78.98	<.0001
nbreMagasin	1.13619	0.18761	2870.90457	36.68	<.0001
latitude	226.87940	44.17337	2064.88984	26.38	<.0001

Limites sur nombre de conditions : 2.0168, 36.204

Aucune autre variable ne correspondait au niveau de signification 0.5000 pour une saisie dans le modèle.

Synthèse de Sélection ascendante								
Etape	Variable entrée	Libellé	Nombre var. dans	R carré partiel	R carré du modèle	C(p)	Valeur F	Pr > F
1	distanceMRT	X3 distance to the nearest MRT station	1	0.4538	0.4538	122.361	342.24	<.0001
2	nbreMagasin	X4 number of convenience stores	2	0.0428	0.4966	82.6354	34.95	<.0001
3	ageMaison	X2 house age	3	0.0445	0.5411	41.2714	39.75	<.0001
4	latitude	X5 latitude	4	0.0301	0.5711	13.9639	28.68	<.0001
5	dateAchat	X1 transaction date	5	0.0112	0.5823	5.0655	10.92	0.0010

Le modèle 2 : $y \sim x_1 + x_2 + x_3 + x_4 + x_5$.

En comparant les modèles 2 et 3 en fonction des valeurs p, du R^2 ajusté et du C(p), les critères suivants peuvent être considérés pour évaluer le meilleur modèle :

1. R^2 ajusté: Les deux modèles ont le même R^2 ajusté final de 0.5823, ce qui signifie qu'ils expliquent tous deux environ 58.23% de la variation dans le prix des maisons.
2. C(p) : Le C(p) mesure la qualité de l'ajustement du modèle tout en pénalisant la complexité du modèle. Un C(p) plus faible indique un meilleur ajustement. Les deux modèles ont des valeurs de C(p) très faibles, ce qui suggère qu'ils sont bien ajustés aux données.
3. P valeurs : Les p-valeurs associées aux coefficients des variables dans les deux modèles sont très faibles ($p < 0.001$), indiquant que toutes les variables incluses dans les modèles sont significatives.

Compte tenu de ces critères, les deux modèles semblent être de qualité comparable. Ils ont des performances similaires en termes de R^2 ajusté et de valeurs p, et les deux modèles ont des valeurs de C(p) faibles, indiquant un bon ajustement et une complexité modérée. Dans ce cas, il n'y a pas de différence significative entre les deux modèles en termes de qualité de l'ajustement.

Méthode 3 : avec LOG(prixMaison)

Analyse de variance					
Source	DDL	Somme des carrés	Moyenne quadratique	Valeur F	Pr > F
Modèle	4	43.02288	10.75572	213.62	<.0001
Erreur	409	20.59329	0.05035		
Total sommes corrigées	413	63.61617			

Variable	Valeur estimée des paramètres	Erreur type	SC Type II	Valeur F	Pr > F
Intercept	-200.86196	27.88510	2.61248	51.89	<.0001
ageMaison	-0.00696	0.00097557	2.56206	50.88	<.0001
distanceMRT	-0.00014476	0.00001235	6.91910	137.42	<.0001
nbreMagasin	0.02842	0.00475	1.79999	35.75	<.0001
latitude	8.19385	1.11670	2.71087	53.84	<.0001

le modèle final inclut `ageMaison`, `distanceMRT`, `nbreMagasin`, et `latitude` comme prédicteurs significatifs du `log\_prixMaison`. Les variables `longitude` et `dateAchat` ont été retirées car elles n'étaient pas significatives. Le modèle explique environ 67.63% de la variabilité dans le prix des maisons (en termes de logarithme).

Le modèle 3 est alors : $y \sim x_2 + x_3 + x_4 + x_5$.

Comparons les trois modèles en fonction des critères suivants :

1. R^2 ajusté : Le modèle d'élimination descendante (modèle 1) a un R^2 ajusté de 0.5823, le modèle 2 a un R^2 ajusté de 0.5824 et le modèle 3 a un R^2 ajusté de 0.6763. On va donc préférer le modèle 3, qui explique le modèle a 67,63%.

2. $C(p)$: Le modèle 3 possède un $C(p)$ moins grand que ceux des modèles 1 et 2. En effet $4.1585 < 5.0655 < 7.0000$.

3. P-valeurs : Toutes les variables restantes dans chaque modèle ont des p-valeurs très faibles ($p < 0.0001$), ce qui indique qu'elles sont toutes significatives.

En résumé, le modèle 3 possède un meilleur R^2 ajusté et un meilleur $C(p)$ que les modèle 1 et 3. Ainsi le modèle plus approprié est : $y \sim -200.86 - 0.0067x_2 - 0.00015x_3 + 0.29x_4 + 8.19x_5$ en ayant pris en compte l'étude des différents modèles. Sans oublier qu'on a le log du prixMaison.

V/ Analyse en composante principale et Classification ascendante hiérarchique

Nous allons faire un ACP suivi d'une CAH de nos données :

```
Standard deviations (1, ..., p=8):
[1] 1.8086440 1.0433462 1.0246401 0.9780671 0.7852866 0.7438200 0.5661195 0.3785478

Rotation (n x k) = (8 x 8):
      PC1      PC2      PC3      PC4      PC5      PC6      PC7      PC8
No  0.008519541 -0.52339392 -0.29615438 -0.79790866 -0.005117844  0.012294774  0.02724784  0.02647219
x1 -0.003886862  0.48983537  0.62425564 -0.55684554 -0.218892422 -0.005972994 -0.09698767 -0.05401816
x2  0.038741801  0.66223705 -0.65844973 -0.17770530 -0.083378433  0.013691530  0.29424365  0.03297262
x3  0.508156797  0.04612734  0.10188509 -0.03576992  0.266993386  0.081843224  0.01719344  0.80604558
x4 -0.415397403  0.11321609 -0.08120112 -0.04816796  0.273833934  0.758506573 -0.38025941  0.10391766
x5 -0.403158817  0.14932007 -0.06147855 -0.09859823  0.538313949 -0.627104985 -0.31419585  0.14108034
x6 -0.442128839 -0.07555561 -0.07778036  0.08914783 -0.677723329 -0.131751623 -0.13811464  0.53765534
y  -0.457840701 -0.06790763  0.24947513 -0.02042200  0.223039552  0.083522551  0.80036499  0.16065110
```

On peut voir que :

1. PC1: Cette composante semble être principalement influencée par les variables x_3 , x_4 , x_5 , x_6 et y . Cela suggère que PC1 pourrait représenter une certaine tendance ou structure dans ces variables. Les coefficients élevés pour ces variables indiquent qu'elles contribuent fortement à PC1.

2. PC2: Les variables x_2 et x_5 ont des coefficients élevés pour PC2, tandis que d'autres variables ont des coefficients plus faibles. Cela suggère que PC2 capture une relation spécifique entre x_2 et x_5 . Les variables x_1 et x_4 ont également des coefficients non négligeables, mais moins importants que x_2 et x_5 .

3. PC3 : Les variables x1, x2 et y semblent avoir les coefficients les plus élevés pour PC3, tandis que les autres variables ont des coefficients plus faibles. Cela suggère que PC3 pourrait représenter une relation entre ces variables en particulier.

4. PC4 : La variable y a le coefficient le plus élevé pour PC4, suivi par x6. Cela suggère que PC4 peut représenter une relation spécifique entre y et x6.


5. PC5 : La variable x5 a le coefficient le plus élevé pour PC5, suivie par x4 et y. Cela suggère que PC5 peut représenter une relation spécifique impliquant ces variables.

6. PC6 : PC6 semble être principalement influencée par les variables x4, x5 et y, bien que les coefficients pour x5 et y soient relativement faibles par rapport à x4.


7. PC7 : La variable y a un coefficient élevé pour PC7, suivie par x6 et x2. Cela suggère que PC7 peut représenter une relation impliquant ces variables.

8. PC8 : Les variables x3 et y ont des coefficients élevés pour PC8, tandis que les autres variables ont des coefficients plus faibles. Cela suggère que PC8 capture une relation spécifique entre x3 et y.

Globalement, l'analyse des composantes principales suggère que les variables x3, x4, x5, x6 et y sont les plus importantes pour expliquer la variance dans les données, tandis que les autres variables ont une contribution plus limitée. Les relations entre ces variables peuvent fournir des informations importantes sur la structure des données et peuvent être utilisées pour une meilleure compréhension des phénomènes sous-jacents.



Les lignes (ou flèches) qui partent de l'origine du graphique et se dirigent vers les points des variables indiquent la contribution des variables à chaque composante principale. Plus la longueur de la ligne est grande, plus la contribution de la variable à cette composante principale est importante. Ainsi on voit que x1 est la variable qui influe le moins sur y. Ce qui est en accord avec notre choix de modèle.




On remarque deux groupes distinctes grace au biplot de notre ACP.

On passe au CAH :

La Classification Ascendante Hiérarchique est une technique statistique visant à mettre une population dans différentes classes ou sous-groupes.

Ici on souhaite séparer nos 414 données dans différents groupes en fonction des relations avec les variables.



On voit dans le dendrogramme qu'il y a une division en 2 groupes aux alentours de 3000, ce qui nous réconforte dans l'observation de notre ACP ci-dessus

Conclusion

Dans cette analyse, notre objectif était de comprendre comment six variables indépendantes - année de transaction, âge de la maison, distance à la station de MRT, nombre de magasins de proximité et région (latitude + longitude) - influent sur le prix des maisons à Taipei, Taïwan.

Nous avons constaté que pas toutes les variables étaient significatives pour prédire les prix des maisons à Taipei, certaines montrant une corrélation positive tandis que d'autres montraient une corrélation négative. Plus précisément, l'année de transaction et le nombre de magasins de proximité ont des relations positives avec le prix des maisons, tandis que l'âge de la maison, la distance de la station de MRT et la région ont des relations négatives avec le prix des maisons. En utilisant le modèle avec transformation logarithmique comme modèle final pour cette analyse, nous avons pu observer des distributions moins asymétriques et faire des interprétations plus simples.

Le logarithme des prix des maisons par unité de Taipei diminuera de 0.0067 pour chaque année supplémentaire dans l'âge de la maison, diminuera de 0.00015 pour chaque mètre supplémentaire jusqu'à la station de MRT la plus proche, augmentera de 0.29 pour chaque magasin de proximité supplémentaire, et augmentera de 8.19 pour chaque changement dans la coordonnée de latitude.
